Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №1
По дисциплине: «ОМО»
Тема:” Знакомство с анализом данных: предварительная обработка и визуализация.”

Выполнил:
Студент 3-го курса
Группы АС-66
Осовец А.О.
Проверил:
Крощенко А.А.

Брест 2025

Цель: Получить практические навыки работы с данными с использованием библиотек Pandas для манипуляции и Matplotlib для визуализации. Научиться выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.

Вариант 7

Выборка Auto MPG. Содержит технические характеристики различных автомобилей и данные о расходе топлива (миль на галлон).
Задачи:
1. Загрузите данные. Обратите внимание, что пропуски в столбце horsepower могут быть обозначены знаком ?.
2. Преобразуйте столбец horsepower в числовой формат и заполните пропуски средним значением.
3. Постройте диаграмму рассеяния, чтобы изучить зависимость расхода топлива (mpg) от веса автомобиля (weight).
4. Преобразуйте категориальный признак origin (страна производства) в числовой.
5. Создайте новый признак age, рассчитав возраст автомобиля относительно года, когда были собраны данные (например, 1983 - model year).
6. Визуализируйте распределение количества цилиндров (cylinders) с помощью столбчатой диаграммы.

```
import os
import pandas as pd
import matplotlib.pyplot as plt
from datetime import datetime

current_dir = os.path.dirname(os.path.abspath(__file__))


project_root = os.path.abspath(os.path.join(current_dir, '..', '..', '..', '..', '..'))

file_path = os.path.join(project_root, 'auto-mpg.csv')
print("Читаем файл из:", file_path)

columns = [
    'mpg', 'cylinders', 'displacement', 'horsepower', 'weight',
    'acceleration', 'model_year', 'origin', 'car_name'
]

# 1) ------------------------
df = pd.read_csv(
    file_path,
    sep=",",
    names=columns,
    na_values='?',
    header=None
```

```
)

numeric_cols = [
    'mpg', 'cylinders', 'displacement', 'horsepower',
    'weight', 'acceleration', 'model_year', 'origin'
]


# 2) ----------------------------------
for col in numeric_cols:
    df[col] = pd.to_numeric(df[col], errors='coerce')

df['model_year'] = 1900 + df['model_year']

df['car_name'] = df['car_name'].astype(str)


# 4) ----------------------------------
df[numeric_cols] = df[numeric_cols].fillna(df[numeric_cols].mean())  # заполняем пропуски
#5) ----------------------------------
current_year = datetime.now().year
df['age'] = current_year - df['model_year']

pd.set_option('display.max_columns', None)


print("\nТипы данных:")
print(df.dtypes)

print("\nКоличество пропусков:")
print(df.isnull().sum())

print("\nОсновные статистические показатели:")
print(df.describe())

print("\nПример новых данных (model_year и age):")
print(df[['model_year', 'age']].head())


# 3)  ----------------------------------

fig1, ax1 = plt.subplots(figsize=(8,6))
ax1.scatter(df['weight'], df['mpg'], alpha=0.7)
ax1.set_xlabel("Вес")
ax1.set_ylabel("MPG (миль на галлон)")
ax1.set_title("Зависимость расхода топлива от веса автомобиля")
ax1.grid(True)
plt.show()
plt.close(fig1)
```

```
fig2, ax2 = plt.subplots(figsize=(8,6))
ax2.hist(df['horsepower'], bins=30, color='skyblue', edgecolor='black')
ax2.set_xlabel("Horsepower")
ax2.set_ylabel("Количество автомобилей")
ax2.set_title("Распределение мощности автомобилей")
ax2.grid(True)
plt.show()
plt.close(fig2)

# 6) ------------------------------------
fig3, ax3 = plt.subplots(figsize=(8,6))
df.boxplot(column='mpg', by='cylinders', ax=ax3)
ax3.set_xlabel("Цилиндры")
ax3.set_ylabel("MPG")
ax3.set_title("MPG по количеству цилиндров")
plt.suptitle("")
ax3.grid(True)
plt.show()
plt.close(fig3)

# Распределения возраста автомобилей
fig4, ax4 = plt.subplots(figsize=(8,6))
ax4.hist(df['age'], bins=20, color='lightgreen', edgecolor='black')
ax4.set_xlabel("Возраст автомобиля (лет)")
ax4.set_ylabel("Количество автомобилей")
ax4.set_title("Распределение возраста автомобилей")
ax4.grid(True)
plt.show()
plt.close(fig4)

# Зависимость MPG от возраста
fig5, ax5 = plt.subplots(figsize=(8,6))
ax5.scatter(df['age'], df['mpg'], alpha=0.7, color='orange')
ax5.set_xlabel("Возраст автомобиля (лет)")
ax5.set_ylabel("MPG (миль на галлон)")
ax5.set_title("Зависимость расхода топлива от возраста автомобиля")
ax5.grid(True)
plt.show()
plt.close(fig5)
```

```
Типы данных:
 mpg             float64
cylinders          int64
displacement     float64
horsepower       float64
weight           float64
acceleration     float64
model_year         int64
origin             int64
car_name          object
dtype: object
```

```
Количество пропусков:
 mpg             0
cylinders        0
displacement     0
horsepower       0
weight           0
acceleration     0
model_year       0
origin           0
car_name         0
dtype: int64
```

```
Основные статистические показатели:
              mpg   cylinders  displacement  horsepower       weight  \
count  399.000000  399.000000    399.000000  399.000000   399.000000
mean    23.514573    5.454774    193.425879  104.469388  2970.424623
std      7.806159    1.698866    104.138764   38.151168   845.777234
min      9.000000    3.000000     68.000000   46.000000  1613.000000
25%     17.500000    4.000000    104.500000   76.000000  2224.500000
50%     23.000000    4.000000    151.000000   95.000000  2807.000000
75%     29.000000    8.000000    262.000000  125.000000  3607.000000
max     46.600000    8.000000    455.000000  230.000000  5140.000000

       acceleration   model_year      origin         age
count    399.000000   399.000000  399.000000  399.000000
mean      15.568090  1976.010050    1.572864   48.989950
std        2.754222     3.692978    0.801047    3.692978
min        8.000000  1970.000000    1.000000   43.000000
25%       13.850000  1973.000000    1.000000   46.000000
50%       15.500000  1976.000000    1.000000   49.000000
75%       17.150000  1979.000000    2.000000   52.000000
max       24.800000  1982.000000    3.000000   55.000000
```

Графики:

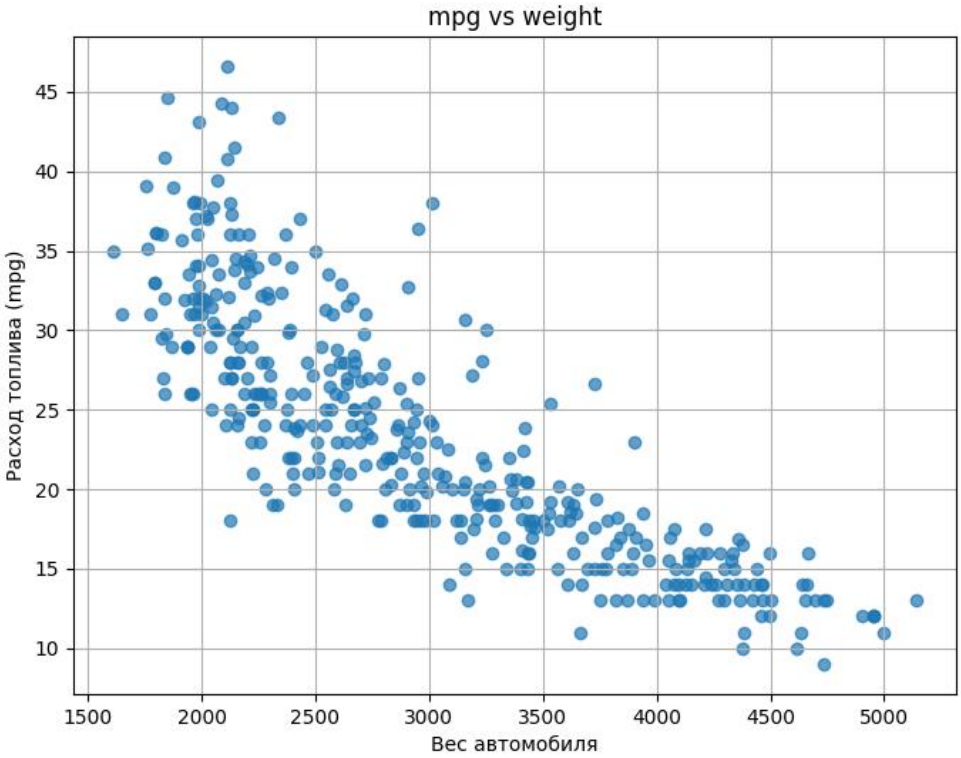
mpg vs weight
Расход топлива (mpg)
Вес автомобиля
45
40
35
30
25
20
15
10
1500
2000
2500
3000
3500
4000
4500
5000

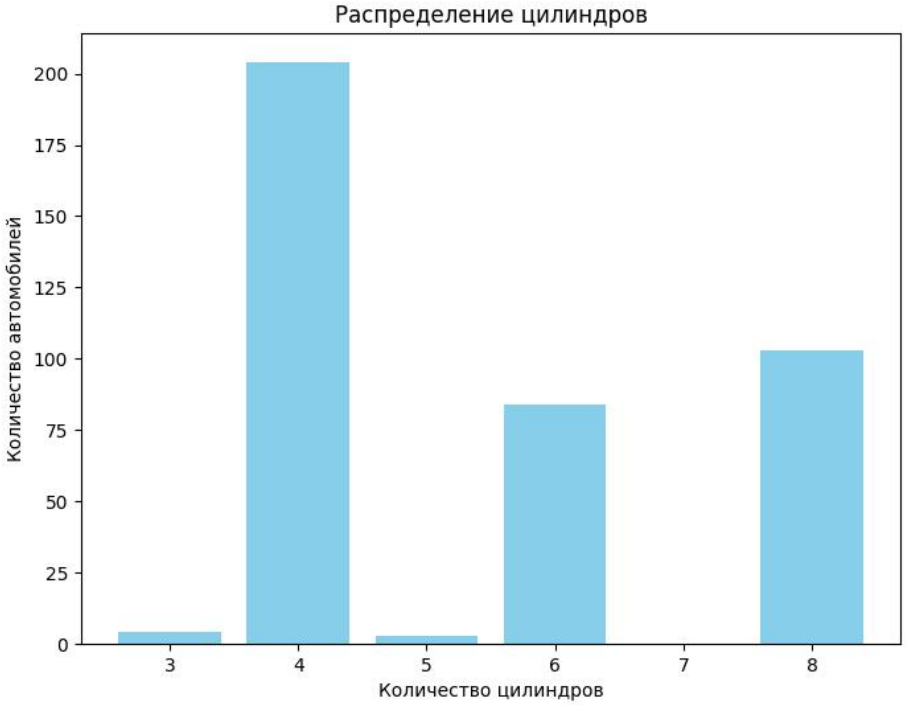
Распределение цилиндров
Количество автомобилей
Количество цилиндров
200
175
150
125
100
75
50
25
0
3
4
5
6
7
8

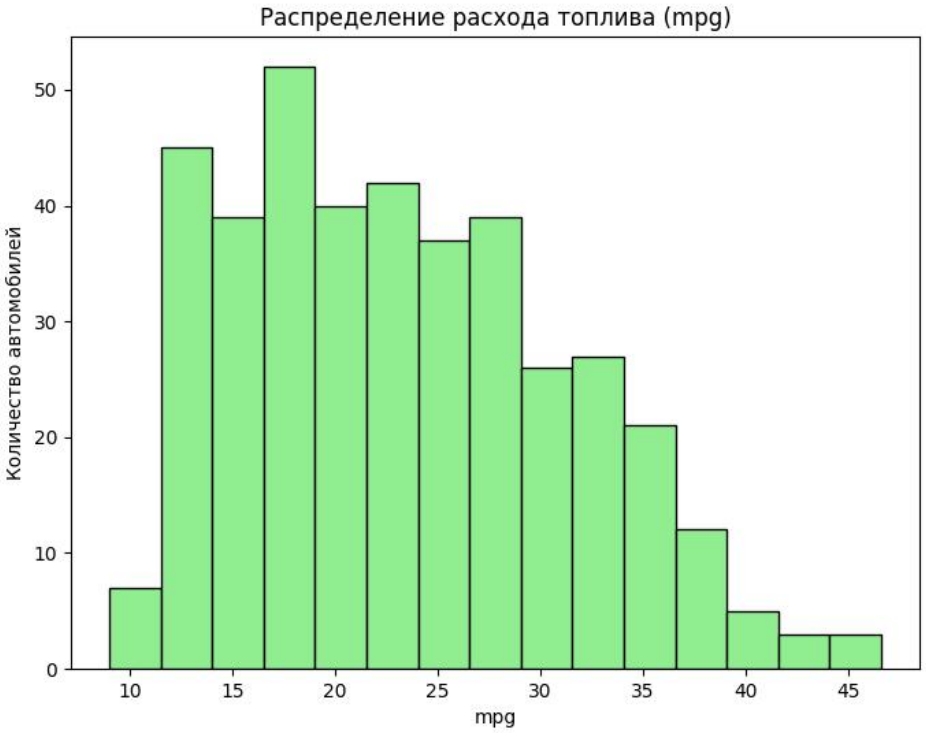
Распределение расхода топлива (mpg)
Количество автомобилей
mpg
0
10
20
30
40
50
10
15
20
25
30
35
40
45

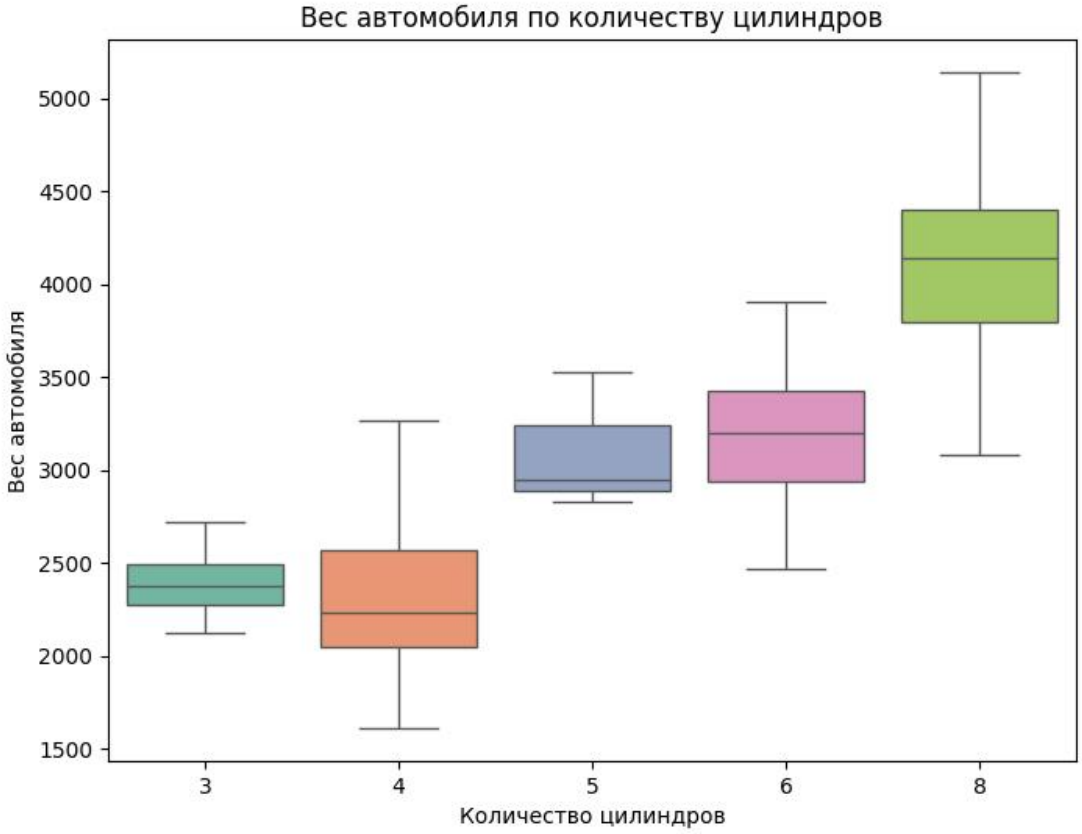

Вывод: в результате выполнения данной лабораторной работы получили практические навыки работы с данными с использованием библиотек Pandas для манипуляции и Matplotlib для визуализации. Научились выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.