

Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №5
По дисциплине: «ОМО»
Тема:” Нелинейные ИНС в задачах регрессии”

Выполнил:
Студент 3-го курса
Группы АС-66
Савинец М.Д.
Проверил:
Крощенко А.А.

Брест 2025

Цель: Выполнить моделирование прогнозирующей нелинейной ИНС.

Вариант 11

Задание:

- Выполнить моделирование прогнозирующей нелинейной ИНС. Для генерации обучающих и тестовых данных использовать функцию

$$y = a \cos(bx) + c \sin(dx) .$$

Варианты заданий приведены в следующей таблице:

№ варианта	a	b	c	d	Кол-во входов ИНС	Кол-во НЭ в скрытом слое
1	0.1	0.1	0.05	0.1	6	2
2	0.2	0.2	0.06	0.2	8	3
3	0.3	0.3	0.07	0.3	10	4
4	0.4	0.4	0.08	0.4	6	2
5	0.1	0.5	0.09	0.5	8	3
6	0.2	0.6	0.05	0.6	10	4
7	0.3	0.1	0.06	0.1	6	2
8	0.4	0.2	0.07	0.2	8	3
9	0.1	0.3	0.08	0.3	10	4
10	0.2	0.4	0.09	0.4	6	2
11	0.3	0.5	0.05	0.5	8	3

```
import numpy as np
import torch
import torch.nn as nn
import torch.optim as optim
import matplotlib.pyplot as plt
import pandas as pd

b = 0.5
c = 0.05
d = 0.5

n_inputs = 8
n_hidden = 3

def generate_series(a, N=2000):
    i = np.arange(N)
    y = a * np.cos(b * i) + c * np.sin(d * i)
    return y

def create_dataset(series, look_back=8):
    X, Y = [], []
    for i in range(look_back, len(series)):
        X.append(series[i - look_back:i])
        Y.append(series[i])
```

```

        return np.array(X, dtype=np.float32), np.array(Y, dtype=np.float32)

# 3. MLP
class MLP(nn.Module):
    def __init__(self, input_size, hidden_size):
        super(MLP, self).__init__()
        self.hidden = nn.Linear(input_size, hidden_size)
        self.output = nn.Linear(hidden_size, 1)
        self.sigmoid = nn.Sigmoid()

    def forward(self, x):
        x = self.sigmoid(self.hidden(x))
        return self.output(x)

# 4. Подбор а: от 0.1 до 0.5 с шагом 0.05
a_values = np.arange(0.1, 0.51, 0.05)
best_a = None
min_test_mse = float('inf')
results = []

print("Q Поиск оптимального а...")
print("-" * 60)

for a in a_values:
    y_full = generate_series(a, N=2000)

    X, Y = create_dataset(y_full, look_back=n_inputs)
    split = int(0.8 * len(X))
    X_train, X_test = X[:split], X[split:]
    Y_train, Y_test = Y[:split], Y[split:]

    X_train_t = torch.tensor(X_train)
    Y_train_t = torch.tensor(Y_train).unsqueeze(1)
    X_test_t = torch.tensor(X_test)
    Y_test_t = torch.tensor(Y_test).unsqueeze(1)

    model = MLP(n_inputs, n_hidden)
    criterion = nn.MSELoss()
    optimizer = optim.Adam(model.parameters(), lr=0.01)

    losses = []
    for epoch in range(1500):
        model.train()
        optimizer.zero_grad()
        pred = model(X_train_t)
        loss = criterion(pred, Y_train_t)
        loss.backward()
        optimizer.step()
        losses.append(loss.item())

    model.eval()
    with torch.no_grad():
        pred_test = model(X_test_t).numpy().flatten()

    test_mse = float(np.mean((Y_test - pred_test) ** 2))
    results.append({'a': round(a, 2), 'test_mse': test_mse})

    if test_mse < min_test_mse:
        min_test_mse = test_mse
        best_a = round(a, 2)
        best_model = model
        best_losses = losses

```

```

    best_split_data = (X_train, Y_train, X_test, Y_test, pred_test)

    print(f'a = {a:.2f} → Test MSE = {test_mse:.8f}')

print("-" * 60)
print(f"✓ Оптимальное a = {best_a} (Test MSE = {min_test_mse:.8f})")

# 5. Результаты для best_a
a = best_a
X_train, Y_train, X_test, Y_test, pred_test = best_split_data

# Обучение на лучших данных (ещё раз, чтобы получить предсказания на обучении)
y_full = generate_series(a, N=2000)
X, Y = create_dataset(y_full)
split = int(0.8 * len(X))
X_train, X_test = X[:split], X[split:]
Y_train, Y_test = Y[:split], Y[split:]

X_train_t = torch.tensor(X_train)
Y_train_t = torch.tensor(Y_train).unsqueeze(1)
X_test_t = torch.tensor(X_test)
Y_test_t = torch.tensor(Y_test).unsqueeze(1)

model = best_model
with torch.no_grad():
    pred_train = model(X_train_t).numpy().flatten()

# 6.1 График функции (первые 200 точек)
plt.figure(figsize=(10, 3))
y_plot = generate_series(a, N=200)
plt.plot(y_plot, label=f'y[i] = {a} · cos({b} · i) + {c} · sin({d} · i)', color='steelblue')
plt.title('Участок временного ряда для обучения (первые 200 точек)')
plt.xlabel('i')
plt.ylabel('y[i]')
plt.grid(True)
plt.legend()
plt.tight_layout()
plt.show()

# 6.2 График ошибки обучения
plt.figure(figsize=(8, 4))
plt.plot(best_losses, color='darkorange')
plt.title(f'Изменение ошибки (MSE) при обучении (a = {best_a})')
plt.xlabel('Эпоха')
plt.ylabel('MSE')
plt.yscale('log')
plt.grid(True)
plt.tight_layout()
plt.show()

# 6.3 Таблица: обучение (первые 10)
train_df = pd.DataFrame({
    'Эталонное значение': Y_train[:10],
    'Полученное значение': pred_train[:10],
    'Отклонение': Y_train[:10] - pred_train[:10]
})
print("\n==== РЕЗУЛЬТАТЫ ОБУЧЕНИЯ (первые 10) ===")
print(train_df.round(6).to_string(index=False))

# 6.4 Таблица: прогнозирование (первые 10)
test_df = pd.DataFrame({

```

```

'Эталонное значение': Y_test[:10],
'Полученное значение': pred_test[:10],
'Отклонение': Y_test[:10] - pred_test[:10]
})
print("\n==== РЕЗУЛЬТАТЫ ПРОГНОЗИРОВАНИЯ (первые 10) ===")
print(test_df.round(6).to_string(index=False))

# 6.5 Метрики
train_mse = np.mean((Y_train - pred_train) ** 2)
test_mse = np.mean((Y_test - pred_test) ** 2)
train_mae = np.mean(np.abs(Y_train - pred_train))
test_mae = np.mean(np.abs(Y_test - pred_test))

print(f"\n[!] Оценка при a = {best_a}:")
print(f"Train → MSE: {train_mse:.8f}, MAE: {train_mae:.8f}")
print(f"Test → MSE: {test_mse:.8f}, MAE: {test_mae:.8f}")

plt.figure(figsize=(10, 4))
plt.plot(Y_test[:100], label='Эталон (тест)', color='blue')
plt.plot(pred_test[:100], label='Прогноз (тест)', color='red', linestyle='--')
plt.title('Сравнение эталона и прогноза (первые 100 точек теста)')
plt.xlabel('Номер точки в тесте')
plt.ylabel('y')
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()

```

Результаты:

==== РЕЗУЛЬТАТЫ ОБУЧЕНИЯ (первые 10) ===

Эталонное значение	Полученное значение	Отклонение
-0.103204	-0.103216	0.000011
-0.069956	-0.070144	0.000188
-0.019580	-0.019532	-0.000048
0.035590	0.035966	-0.000376
0.082046	0.082182	-0.000135
0.108415	0.108021	0.000394
0.108240	0.107871	0.000369
0.081564	0.081751	-0.000187
0.034918	0.035322	-0.000405
-0.020277	-0.020250	-0.000027

==== РЕЗУЛЬТАТЫ ПРОГНОЗИРОВАНИЯ (первые 10) ===

Эталонное значение	Полученное значение	Отклонение
-0.053702	-0.053901	0.000200
-0.094141	-0.094285	0.000144
-0.111531	-0.111450	-0.000082
-0.101615	-0.101643	0.000028
-0.066820	-0.067007	0.000188
-0.015665	-0.015587	-0.000078
0.039326	0.039707	-0.000382
0.084688	0.084785	-0.000097
0.109315	0.108898	0.000418
0.107179	0.106840	0.000338

a = 0.10 → Test MSE = 0.00000006
 a = 0.15 → Test MSE = 0.00000257
 a = 0.20 → Test MSE = 0.00000154
 a = 0.25 → Test MSE = 0.00000175
 a = 0.30 → Test MSE = 0.00000227
 a = 0.35 → Test MSE = 0.00000986
 a = 0.40 → Test MSE = 0.00000468
 a = 0.45 → Test MSE = 0.00001953
 a = 0.50 → Test MSE = 0.00001353

Figure 1

Участок временного ряда для обучения (первые 200 точек)

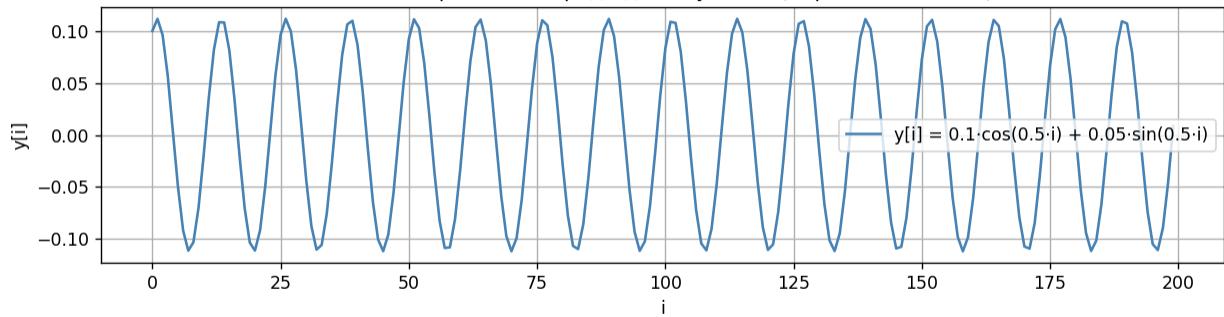
[Home](#) [Left](#) [Right](#) [Zoom In](#) [Zoom Out](#) [Search](#) [Help](#)

Figure 1

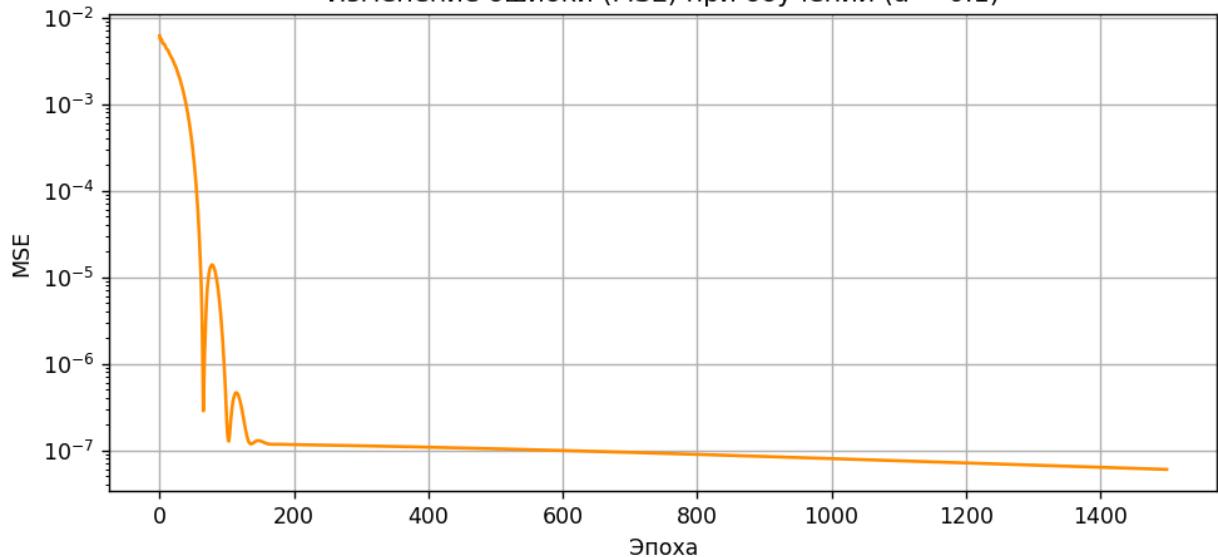
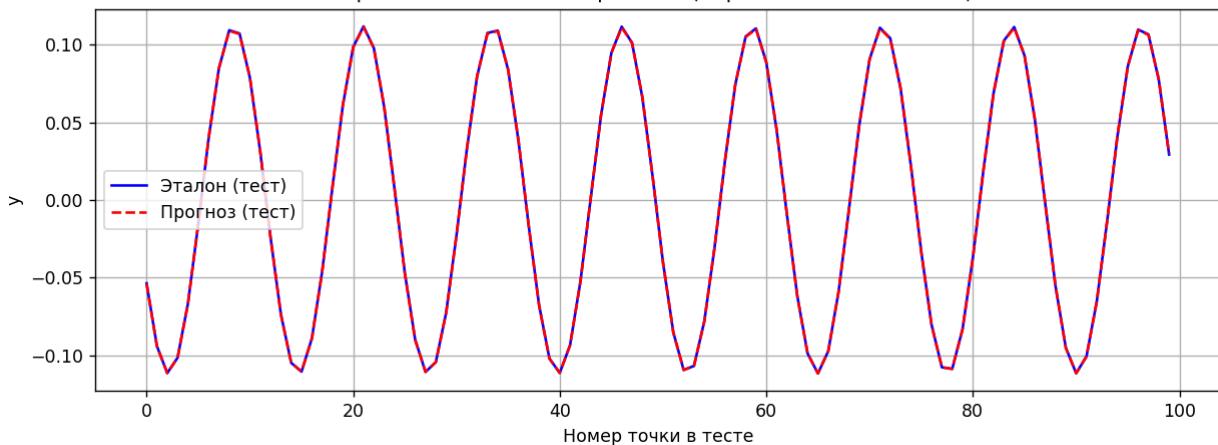
Изменение ошибки (MSE) при обучении ($\alpha = 0.1$)

Figure 1

Сравнение эталона и прогноза (первые 100 точек теста)



Вывод: На практике выполнили моделирование прогнозирующей нелинейной ИНС.